

自然语言处理

第二章 隐马尔科夫模型



- 马尔科夫模型 (Markov Model)
 - 最早由Andrei A. Markov (切比雪夫Chebyshev的一个学生) 于1913年提出, 它的最原始目的是为了语言上的应用
- 隐马尔科夫模型 (Hidden Markov Model, HMM)
 - 其数学思想是由Baum等人于1966~1970提出
 - 从某种意义上讲, HMM本身是一个马尔科夫过程的概率函数
 - 在20世纪70年代被CMU的Baker以及IBM的Jelinek等人应用在了语音处理上
 - 之后被广泛应用在了汉语自动分词、词性标注、统计机器翻译等很多方面

目录

Contents

3.1

马尔科夫模型

3.2

隐马尔科夫模型

3.3

HMM的三个基本问题



- Markov, 1913
- 随机过程
 - 又称“随机函数”，是随时间而随机变化的过程
- 马尔科夫模型描述了一类重要的随机过程

设系统有 N 个状态 $S = \{s_1, s_2, \dots, s_N\}$,

随着时间的推移，系统将从某一状态转移到另一状态。

$Q = \{q_1, q_2, \dots, q_T\}$ 为一随机变量序列， $q_t \in S$, $t = 1, 2, \dots, T$

则系统在时间 t 处于状态 s_j 的概率取决于其在时间 $1, 2, \dots, t-1$ 的状态

$$P(q_t = s_j \mid q_{t-1} = s_i, q_{t-2} = s_k, \dots)$$



- 一阶马尔可夫过程

- 如果系统在 t 时间的状态只与其在时间 $t-1$ 的状态相关, 则该随机过程称为一阶马尔可夫过程

$$P(q_t = s_j \mid q_{t-1} = s_i, q_{t-2} = s_k, \dots) \approx P(q_t = s_j \mid q_{t-1} = s_i)$$

- 马尔可夫模型

- 独立于时间 t 的随机过程

$$P(q_t = s_j \mid q_{t-1} = s_i) = a_{ij}, (1 \leq i, j \leq N)$$

a_{ij} 称为状态转移概率


a_{ij} 须满足以下条件

1) $a_{ij} \geq 0$

2) $\sum_{j=1}^N a_{ij} = 1$



天气变化的例子



- 状态：晴朗，多云，下雨
- 状态转移概率矩阵

		今天		
		晴朗	多云	下雨
昨天	晴朗	0.50	0.375	0.125
	多云	0.25	0.125	0.625
	下雨	0.25	0.375	0.375

- 初始概率矩阵

晴朗	多云	下雨
(0.63	0.17	0.20)



马尔科夫模型的形式化定义

$$\mu = (S, A, \pi)$$

$S = \{s_i\} \rightarrow$ 状态集合

$A = \{a_{ij}\} \rightarrow$ 状态转移概率矩阵

$\pi = \{\pi_i\} \rightarrow$ 初始概率矩阵

{ 晴朗, 多云, 下雨 }

		今天		
		晴朗	多云	下雨
昨天	晴朗	0.50	0.375	0.125
	多云	0.25	0.125	0.625
	下雨	0.25	0.375	0.375

		晴朗	多云	下雨
		0.63	0.17	0.20



马尔科夫模型在NLP中的应用举例

$$S = \{s_1 = n, s_2 = v, s_3 = a\}$$

$$A = (a_{ij}) = \begin{matrix} & \begin{matrix} n & v & a \end{matrix} \\ \begin{matrix} n \\ v \\ a \end{matrix} & \begin{bmatrix} 0.3 & 0.5 & 0.2 \\ 0.5 & 0.3 & 0.2 \\ 0.4 & 0.2 & 0.4 \end{bmatrix} \end{matrix}$$

$$\pi = \{\pi_i\} = \begin{matrix} & \begin{matrix} n & v & a \end{matrix} \\ \begin{bmatrix} 0.6 & 0.2 & 0.2 \end{bmatrix} \end{matrix}$$

$$\begin{aligned} & P(q_1 = n, q_2 = v, q_3 = a, q_4 = n) \\ &= P(q_1 = n) \times P(q_2 = v | q_1 = n) \times P(q_3 = a | q_2 = v) \times P(q_4 = n | q_3 = a) \\ &= 0.6 \times 0.5 \times 0.2 \times 0.4 \\ &= 0.024 \end{aligned}$$

目录

Contents

3.1


马尔科夫模型

3.2

隐马尔科夫模型

3.3

HMM的三个基本问题





HMM的形式化定义

$$\mu = (S, V, A, B, \pi)$$


$S \rightarrow$ 状态集合(hidden states)

$V \rightarrow$ 观察值(输出符号)集合

$A = \{a_{ij}\} \rightarrow$ 转移概率矩阵

$B = (b_{ik}) \rightarrow$ 发射概率矩阵

$\pi = \{\pi_i\} \rightarrow$ 初始概率矩阵



晴朗 多云 下雨
(0.63 0.17 0.20)

转移概率A		today		
		晴	阴	雨
yesterday	晴	0.50	0.375	0.125
	阴	0.25	0.125	0.625
	雨	0.25	0.375	0.375

发射概率B		显式状态			
		干透	较干	潮湿	湿透
隐式状态	晴	0.60	0.20	0.15	0.05
	阴	0.25	0.25	0.25	0.25
	雨	0.05	0.10	0.35	0.50

为了简单, 有时也将其记为 $\mu = (A, B, \pi)$

目录

Contents

3.1

马尔科夫模型

3.2

隐马尔科夫模型

3.3

HMM的三个基本问题

3.2.1 计算观察值序列的概率

3.2.2 确定最优状态序列

3.2.3 HMM的参数估计



HMM涉及的三个基本问题

(1) 给定模型 $\mu=(A,B,\pi)$, 如何有效地计算某个观察序列 $O=o_1o_2\ldots o_T$ 出现的概率?

$$P(O|\mu)=?$$

— 例: $P(\text{干透}, \text{潮湿}, \text{湿透})=?$



(1) 给定模型 $\mu=(A,B,\pi)$, 如何有效地计算某个观察序列 $O=o_1o_2\ldots o_T$ 出现的概率?

$$P(O|\mu)=?$$

– 前向(Forward Algorithm)算法 (4.2.1)

(2) 给定模型 $\mu=(A,B,\pi)$ 和观察序列 $O=o_1o_2\ldots o_T$, 如何有效地确定一个状态序列 $Q=q_1q_2\ldots q_T$, 以便最好地解释观察序列?

$$\arg \max_Q P(Q|O)=?$$

– 例: 已知 $O=$ “干透, 潮湿, 湿透”, 求 $Q=q_1q_2q_3=?$



(1) 给定模型 $\mu=(A,B,\pi)$, 如何有效地计算某个观察序列 $O=o_1o_2\ldots o_T$ 出现的概率?

$$P(O|\mu)=?$$

– 前向(Forward Algorithm)算法 (4.2.1)

(2) 给定模型 $\mu=(A,B,\pi)$ 和观察序列 $O=o_1o_2\ldots o_T$, 如何有效地确定一个状态序列 $Q=q_1q_2\ldots q_T$, 以便最好地解释观察序列?

$$\arg \max_Q P(Q|O)=?$$

– 维特比(Viterbi)算法 (4.2.2)

(3) 给定一个观察序列 $O=o_1o_2\ldots o_T$, 如何找到一个能够最好地解释这个观察序列的模型, 即如何调节模型参数 $\mu=(A,B,\pi)$, 使得 $P(O|\mu)$ 最大化?

$$\arg \max_{\mu} P(O|\mu)=?$$

– Baum-Welch算法 (4.2.3)



- 问题的定义
 - 给定模型 $\mu=(A,B,\pi)$ 和观察序列 $O=o_1o_2\ldots o_T$ ，如何计算观察序列 O 的概率 $P(O)$ 。
- 例：给定模型 $\mu=(A,B,\pi)$

转移概率A		today		
		晴	阴	雨
yesterday	晴	0.50	0.375	0.125
	阴	0.25	0.125	0.625
	雨	0.25	0.375	0.375

发射概率B		显式状态			
		干透	较干	潮湿	湿透
隐式状态	晴	0.60	0.20	0.15	0.05
	阴	0.25	0.25	0.25	0.25
	雨	0.05	0.10	0.35	0.50

和观察序列 $O=o_1o_2o_3$ =干透, 潮湿, 湿透,
求 $P(O)$ 即 $P(\text{干透}, \text{潮湿}, \text{湿透})=?$




例：令 $O=o_1o_2o_3$ =干透, 潮湿, 湿透,
求 $P(O)$ 即 $P(\text{干透}, \text{潮湿}, \text{湿透})=?$

观察值序列 O : 干透

潮湿

湿透



$Q_1 = \text{晴, 晴, 晴}$

$Q_2 = \text{阴, 晴, 晴}$

$Q_3 = \text{雨, 晴, 晴}$

$Q_4 = \text{晴, 阴, 晴}$

$Q_5 = \text{阴, 阴, 晴}$

$Q_6 = \text{雨, 阴, 晴}$

.....

$Q_{27} = \text{雨, 雨, 雨}$

$$P(O) = P(O, Q_1) + P(O, Q_2) + P(O, Q_3) + \cdots + P(O, Q_{27}) = \sum_Q P(O, Q)$$

$P(\text{干透}, \text{潮湿}, \text{湿透}) =$

$P(\text{干透}, \text{潮湿}, \text{湿透}, \text{晴, 晴, 晴}) +$

$P(\text{干透}, \text{潮湿}, \text{湿透}, \text{阴, 晴, 晴}) +$

$P(\text{干透}, \text{潮湿}, \text{湿透}, \text{雨, 晴, 晴}) +$

.....+

$P(\text{干透}, \text{潮湿}, \text{湿透}, \text{雨, 雨, 雨})$

$27 = 3^3$ 项


时间复杂性 $O(N^T)$



计算公式

具体到每一条路径.....

$$P(O) = \sum_Q P(O, Q)$$



$$P(O, Q) = P(Q)P(O|Q)$$

$$P(Q)$$

$$= P(q_1 q_2 \cdots q_T)$$

$$\approx P(q_1 | q_0) P(q_2 | q_1) \cdots P(q_T | q_{T-1})$$

$$= \pi_{q_1} a_{q_1 q_2} a_{q_2 q_3} \cdots a_{q_{T-1} q_T}$$

↑
转移概率

$$P(O|Q)$$

$$= P(o_1 o_2 \cdots o_T | Q)$$

独立性假设

$$\approx P(o_1 | Q) P(o_2 | Q) \cdots P(o_T | Q)$$

$$= \prod_{t=1}^T P(o_t | Q)$$

$$= \prod_{t=1}^T P(o_t | q_1 q_2 \cdots q_T)$$

$$\approx \prod_{t=1}^T P(o_t | q_t)$$

$$= b_{q_1}(o_1) \times b_{q_2}(o_2) \times \cdots \times b_{q_T}(o_T)$$

↑
发射概率

$$\Rightarrow P(O, Q) = \prod_{t=1}^T [a_{q_{t-1} q_t} b_{q_t}(o_t)]$$



Example

$$P(O, Q) = \prod_{t=1}^T [a_{q_{t-1}q_t} b_{q_t}(o_t)]$$

$P(\text{干透 潮湿 湿透; 雨 阴 晴})$

$$= [\pi_{\text{雨}} \times b_{\text{雨 干透}}] \times [a_{\text{雨 阴}} \times b_{\text{阴 潮湿}}] \times [a_{\text{阴 晴}} \times b_{\text{晴 湿透}}]$$

$$= 0.20 \times 0.05 \times 0.375 \times 0.25 \times 0.25 \times 0.05$$

$$\approx 1.17 \times 10^{-5}$$

隐式状态	初始概率
晴	0.63
阴	0.17
雨	0.20

转移概率A		today		
		晴	阴	雨
yesterday	晴	0.50	0.375	0.125
	阴	0.25	0.125	0.625
	雨	0.25	0.375	0.375


发射概率B		显式状态			
		干透	较干	潮湿	湿透
隐式状态	晴	0.60	0.20	0.15	0.05
	阴	0.25	0.25	0.25	0.25
	雨	0.05	0.10	0.35	0.50



采用动态规划方法降低复杂度


$$\sum_{i=1}^3 a_{q_0 q_i} b_{q_i}(o_1) a_{q_i q_1} b_{q_1}(o_2) a_{q_1 q_1} b_{q_1}(o_3)$$

$$= [\sum_{i=1}^3 a_{q_0 q_i} b_{q_i}(o_1) a_{q_i q_1} b_{q_1}(o_2)] a_{q_1 q_1} b_{q_1}(o_3)$$



$$\sum_{i=1}^3 a_{q_0 q_i} b_{q_i}(o_1) a_{q_i q_1} b_{q_1}(o_2) a_{q_1 q_2} b_{q_2}(o_3)$$

$$= [\sum_{i=1}^3 a_{q_0 q_i} b_{q_i}(o_1) a_{q_i q_1} b_{q_1}(o_2)] a_{q_1 q_2} b_{q_2}(o_3)$$






动态规划 (Dynamic Programming)

• 前向变量 $\alpha_t(i)$

– 在时刻 t , 以状态 s_i 结束时总的概率。

$$\alpha_t(i) = P(o_1 o_2 \cdots o_t, q_t = s_i) \quad (1 \leq i \leq N)$$


– Example



• 递归关系

$$\alpha_1(i) = P(o_1, q_1 = s_i) = \pi_i b_i(o_1), \quad 1 \leq i \leq N$$

$$\alpha_{t+1}(j) = \sum_{i=1}^N [\alpha_t(i) a_{ij} b_j(o_{t+1})] = \left[\sum_{i=1}^N \alpha_t(i) a_{ij} \right] b_j(o_{t+1}) \quad (1 \leq j \leq N)$$






Example

隐式状态	初始概率
晴	0.63
阴	0.17
雨	0.20

转移概率A		today		
		晴	阴	雨
yesterday	晴	0.50	0.375	0.125
	阴	0.25	0.125	0.625
	雨	0.25	0.375	0.375



发射概率B		显式状态			
		干透	较干	潮湿	湿透
隐式状态	晴	0.60	0.20	0.15	0.05
	阴	0.25	0.25	0.25	0.25
	雨	0.05	0.10	0.35	0.50

$$P(\text{晴}) = (0.63 \times 0.50 \times 0.60) + (0.17 \times 0.25 \times 0.25) + (0.20 \times 0.25 \times 0.05) = 0.1905$$

时间复杂性 $O(N^2T)$



前向算法

第1步：初始化


$$a_1(i) = \pi_i b_i(o_1), \quad 1 \leq i \leq N$$

第2步：递归计算

$$a_{t+1}(j) = \left(\sum_{i=1}^N a_t(i) a_{ij} \right) b_j(o_{t+1}), \quad 1 \leq j \leq N, \quad 1 \leq t \leq T-1$$



第3步：求和结束

$$P(O | \mu) = \sum_{i=1}^N a_T(i)$$





后向算法





- 后向变量 $\beta_t(i)$


在时间 t 状态为 s_i 的条件下, HMM 输出序列 $o_{t+1}o_{t+2} \cdots o_T$ 的概率

$$\beta_t(i) = P(o_{t+1}o_{t+2} \cdots o_T \mid q_t = s_i)$$

- 递归关系

$$\beta_T(i) = 1, \quad 1 \leq i \leq N$$

$$\beta_{t-1}(i) = \sum_{j=1}^N a_{ij} b_j(o_t) \beta_t(j) \quad (1 \leq i \leq N, T \geq t \geq 2)$$





第1步：初始化

$$\beta_T(i) = 1, \quad 1 \leq i \leq N$$

第2步：递归计算


$$\beta_{t-1}(i) = \sum_{j=1}^N a_{ij} b_j(o_t) \beta_t(j), \quad 1 \leq i \leq N; \quad T \geq t \geq 2$$

第3步：求和结束

$$P(O | \mu) = \sum_{i=1}^N \pi_i b_i(o_1) \beta_1(i)$$



前向算法和后向算法相结合



前向算法: $P(O) = \sum_{i=1}^N a_T(i)$

后向算法: $P(O) = \sum_{i=1}^N \pi_i b_i(o_1) \beta_1(i)$

$$P(O) = \sum_{i=1}^N a_t(i) \beta_t(i), \quad 1 \leq t \leq T$$



推导过程

$$P(O) = P(o_1 \cdots o_T, q_t = s_1) + P(o_1 \cdots o_T, q_t = s_2) + \cdots + P(o_1 \cdots o_T, q_t = s_N)$$

$$= \sum_{i=1}^N P(o_1 \cdots o_T, q_t = s_i)$$

$$P(o_1 \cdots o_T, q_t = s_i)$$

$$= P(o_1 \cdots o_t, q_t = s_i, o_{t+1} \cdots o_T)$$

$$= P(o_1 \cdots o_t, q_t = s_i) \times P(o_{t+1} \cdots o_T \mid o_1 \cdots o_t, q_t = s_i)$$

$$\approx P(o_1 \cdots o_t, q_t = s_i) \times P(o_{t+1} \cdots o_T \mid q_t = s_i)$$

$$= a_t(i) \beta_t(i)$$

$$a_t(i) = P(o_1 o_2 \cdots o_t, q_t = s_i)$$

$$\beta_t(i) = P(o_{t+1} o_{t+2} \cdots o_T \mid q_t = s_i)$$


$$P(O) = \sum_{i=1}^N a_t(i) \beta_t(i), \quad 1 \leq t \leq T$$



• 问题的定义

- 给定模型 $\mu=(A,B,\pi)$ 和观察序列 $O=o_1o_2\cdots o_T$ ，如何确定最优的状态序列 $Q=q_1q_2\cdots q_T$ ，即

$$\hat{Q} = \arg \max_Q P(Q | O)$$




Max {

- P(干透, 潮湿, 湿透, 晴, 晴, 晴)
- P(干透, 潮湿, 湿透, 阴, 晴, 晴)
- P(干透, 潮湿, 湿透, 雨, 晴, 晴)
-
- P(干透, 潮湿, 湿透, 雨, 雨, 雨)




最优路径求解问题



- 直线表示边
- 波状线表示两节点间的最优路径（路径中其它节点未显示）
- 粗线表示从起点到终点的最优路径

• 最优路径的重要特征

- 如果从起点A经过H、P到达终点G是一条最优路径，那么，由A出发经过H到达P所走的这条子路径，对于从A出发到P的所有可能的路径来说，必定也是最优路径。
 - 全局最优→局部最优
 - 局部最优是全局最优的必要条件
- A到G的最优路径由**终点G**到其相邻节点的距离及**终点G**的相邻节点到**起点A**的最优路径决定。



- 起点S到终点E的最优路径由终点E到其相邻节点的距离及终点E的相邻节点到起点S的最优路径决定
- 逐段计算最优子路径
 - 每增加一个节点，都把它跟前面计算的最优路径连接起来，到最后一段时，只要看看作为终点的节点谁的累积概率最大即可
- 解决办法——动态规划 (Dynamic Programming)
 - 每个节点里存储什么信息？



维特比变量


- 维特比变量 $\delta_t(i)$
 - 到这个节点的概率最大路径的概率

$$\delta_t(i) = \max_{q_1, q_2, \dots, q_{t-1}} P(q_1, q_2, \dots, q_{t-1}, q_t = s_i, o_1 o_2 \dots o_t) \quad (1 \leq i \leq N)$$

- 递归关系


$$\delta_1(i) = \pi_i b_i(o_1) \quad (1 \leq i \leq N)$$

$$\delta_{t+1}(i) = \max_j [\delta_t(j) \times a_{ji}] \times b_i(o_{t+1}) \quad (1 \leq i \leq N)$$





- 反向指针 $\psi_t(i)$
 - 记录导致这条最优路径的前导节点



$$\psi_t(i) = \arg \max_j [\delta_{t-1}(j) \times a_{ji}] \times b_i(o_t) \quad (1 \leq i \leq N)$$


$$\delta_t(i) = \max_j [\delta_{t-1}(j) \times a_{ji}] \times b_i(o_t) \quad (1 \leq i \leq N)$$



示例

隐式状态	初始概率
晴	0.63
阴	0.17
雨	0.20

A		today		
		晴	阴	雨
yesterday	晴	0.50	0.375	0.125
	阴	0.25	0.125	0.625
	雨	0.25	0.375	0.375



B		显式状态			
		干透	较干	潮湿	湿透
隐式状态	晴	0.60	0.20	0.15	0.05
	阴	0.25	0.25	0.25	0.25
	雨	0.05	0.10	0.35	0.50

$$\begin{aligned}
 \delta_1(\text{晴}) &= \max(0.63 \times 0.50, 0.17 \times 0.25, 0.20 \times 0.25) = 0.315 \\
 &= \max(0.315, 0.0425, 0.01) = 0.315 \\
 &\approx 0.315
 \end{aligned}$$



Viterbi算法

第1步：初始化

$$\delta_1(i) = \pi_i b_i(o_1), \quad 1 \leq i \leq N$$

$$\psi_1(i) = 0$$

第2步：递归计算

$$\delta_{t+1}(i) = \max_j [\delta_t(j) \times a_{ji}] \times b_i(o_{t+1}), \quad 1 \leq t \leq T-1, \quad 1 \leq i \leq N$$

$$\psi_{t+1}(i) = \arg \max_j [\delta_t(j) \times a_{ji}] \times b_i(o_{t+1})$$

第3步：路径回溯

$$\hat{q}_T = \arg \max_i \delta_T(i)$$

$$\hat{q}_{t-1} = \psi_t(\hat{q}_t), \quad T \geq t \geq 2$$



- 在实际应用中，人们通常不仅仅只需要算出最佳状态序列，还需要得到可能的路径中的 n 个最佳 (n -best) 序列。
- 为了实现这一点，通常存储一个节点的 n 个最优的先前状态
- 在实践中，一个快速的Viterbi算法是非常重要的，因为这是一个实时算法。训练通常可以按离线方式慢慢完成。



- 问题定义
 - 给定一个观察序列 $O=o_1o_2\ldots o_T$, 调节模型参数 $\mu=(A,B,\pi)$, 使得 $P(O|\mu)$ 最大化。即

$$\arg \max_{\mu} P(O_{training} | \mu)$$



- 状态序列 $Q=q_1q_2\ldots q_T$ 已知

	1	2	3	4	5	6	7	...
	干燥	潮湿	湿透	潮湿	干燥	潮湿	湿透	...
晴	1	0	1	0	0	1	0	...
阴	0	1	0	0	1	0	0	...
雨	0	0	0	1	0	0	1	...

— 最大似然法

$$\bar{\pi}_i = p(q_1 = s_i)$$

$$\bar{a}_{ij} = \frac{A(s_i s_j)}{A(s_i)}$$

$$\bar{b}_i(k) = \frac{A(s_i v_k)}{A(s_i)}$$



- 状态序列 $Q=q_1q_2\ldots q_T$ 未知

	1	2	3	4	5	6	7	...
	干燥	潮湿	湿透	潮湿	干燥	潮湿	湿透	...
晴								
阴								
雨								

- 目前没有已知的解析方法来得到全局最优值
- 但是可以通过迭代爬山算法得到局部最优值，这种算法被称为 **Baum-Welch** 或 **前向后向算法** (Forward-Backward Algorithm) [Baum, 1972]，它实际上是 **EM** (Expectation Maximization) 算法 [Dempster, 1977] 的一个特例



$X \rightarrow$ Complete data

$Y \rightarrow$ Observed data

$$\vec{\theta} = (\theta_1, \theta_2, \dots, \theta_n)$$



$$\tilde{p}(X) = p(X | Y, \vec{\theta})$$


	1	2	3	4	5	6	7	...
	干燥	潮湿	湿透	潮湿	干燥	潮湿	湿透	...
晴								
阴								
雨								

Diagram illustrating the relationship between observed data (Y) and complete data (X) in a Hidden Markov Model (HMM) context. The table shows a sequence of hidden states (晴, 阴, 雨) and their corresponding observed data (干燥, 潮湿, 湿透). The observed data is labeled Y, and the complete data (including hidden states) is labeled X. The difference between X and Y is labeled X - Y.



$X \rightarrow$ Complete data

$Y \rightarrow$ Observed data



	1	2	3	4	5	6	7	...
	干燥	潮湿	湿透	潮湿	干燥	潮湿	湿透	...
晴	1	0	1	0	0	1	0	...
阴	0	1	0	0	1	0	0	...
雨	0	0	0	1			1	...

Y

对比

	1	2	3	4	5	6	7	...
	干燥	潮湿	湿透	潮湿	干燥	潮湿	湿透	...
晴	0.80	0.20	0.5	0.05	0.15	0.70	0.10	...
阴	0.10	0.70	0.30	0.05	0.75	0.15	0.05	...
雨	0.10	0.10	0.20	0.90	0.10	0.15	0.85	...

X - Y



Example

- 投硬币实验
 - 一个人兜里有两枚硬币 c_1 和 c_2
 - 硬币 c_1 掷为正面的概率为 h_1 , 硬币 c_2 掷为正面的概率为 h_2
 - 每一次选择一枚硬币投掷三下, 选择硬币 c_1 的概率为 λ , 则选择硬币 c_2 的概率为 $1-\lambda$

模型 $\theta = (\lambda, h_1, h_2)$

Observed data $Y = \{ \langle HHH \rangle, \langle TTT \rangle, \langle HHH \rangle, \langle TTT \rangle \}$

Complete data $Y = \{ \langle HHH \ c_1/c_2 \rangle, \langle TTT \ c_1/c_2 \rangle, \langle HHH \ c_1/c_2 \rangle, \langle TTT \ c_1/c_2 \rangle \}$



	λ	h_1	h_2		<i>HHH</i>	<i>TTT</i>	<i>HHH</i>	<i>TTT</i>
Θ_0	0.3000	0.3000	0.6000	c_1	0.0508	0.6967	0.0508	0.6967
				c_2	0.9492	0.3033	0.9492	0.3033
Θ_1	0.3738	0.0680	0.7578	c_1	0.0004	0.9714	0.0004	0.9714
				c_2	0.9996	0.0286	0.9996	0.0286
Θ_2	0.4859	0.0004	0.9722	c_1	0.0000	1.0000	0.0000	1.0000
				c_2	1.0000	0.0000	1.0000	0.0000
Θ_3	0.5000	0.0000	1.0000	c_1	0.0000	1.0000	0.0000	1.0000
				c_2	1.0000	0.0000	1.0000	0.0000

$$\begin{aligned}
 & P(c_1 | HHH) \\
 &= \frac{P(c_1, HHH)}{P(HHH)} \\
 &= \frac{P(c_1)P(HHH | c_1)}{P(HHH)} \\
 &= \frac{P(c_1)P(HHH | c_1)}{P(c_1, HHH) + P(c_2, HHH)} \\
 &= \frac{\lambda h_1 h_1 h_1}{\lambda h_1 h_1 h_1 + (1 - \lambda) h_2 h_2 h_2}
 \end{aligned}$$



样本 $Y_2 = \{ \langle HHH \rangle, \langle TTT \rangle, \langle HHH \rangle, \langle TTT \rangle, \langle HHH \rangle \}$

Iteration	λ	h_1	h_2	HHH	TTT	HHH	TTT	HHH
0	0.3000	0.3000	0.6000	0.0508	0.6967	0.0508	0.6967	0.0508
1	0.3092	0.0987	0.8244	0.0008	0.9837	0.0008	0.9837	0.0008
2	0.3940	0.0012	0.9893	0.0000	1.0000	0.0000	1.0000	0.0000
3	0.4000	0.0000	1.0000	0.0000	1.0000	0.0000	1.0000	0.0000



	λ	h_1	h_2	HHH	TTT	HHH	TTT
0	0.3000	0.3000	0.6000	0.0508	0.6967	0.0508	0.6967
1	0.3738	0.0680	0.7578	0.0004	0.9714	0.0004	0.9714
2	0.4859	0.0004	0.9722	0.0000	1.0000	0.0000	1.0000
3	0.5000	0.0000	1.0000	0.0000	1.0000	0.0000	1.0000

$p(c_1 | \dots)$



样本 $Y3=\{<HHT>, <TTT>, <HHH>, <TTT>\}$

Iteration	λ	h_1	h_2	<i>HHT</i>	<i>TTT</i>	<i>HHH</i>	<i>TTT</i>
0	0.3000	0.3000	0.6000	0.1579	0.6967	0.0508	0.6967
1	0.4005	0.0974	0.6300	0.0375	0.9065	0.0025	0.9065
2	0.4632	0.0148	0.7635	0.0014	0.9842	0.0000	0.9842
3	0.4924	0.0005	0.8205	0.0000	0.9941	0.0000	0.9941
4	[0.4970]	0.0000	[0.8284]	0.0000	0.9949	0.0000	0.9949



	λ	h_1	h_2	<i>HHH</i>	<i>TTT</i>	<i>HHH</i>	<i>TTT</i>
0	0.3000	0.3000	0.6000	0.0508	0.6967	0.0508	0.6967
1	0.3738	0.0680	0.7578	0.0004	0.9714	0.0004	0.9714
2	0.4859	0.0004	0.9722	0.0000	1.0000	0.0000	1.0000
3	0.5000	0.0000	1.0000	0.0000	1.0000	0.0000	1.0000



步骤小结

$$\cdot = \{\lambda, h_1, h_2\}$$



• Estimation Step

$\tilde{p}_i = P(X_i = \langle Y_i, c_1 \rangle | Y_i, \cdot) \rightarrow$ 第*i*次选择的是硬币 c_1 的先验概率


$$\begin{aligned} \tilde{p}_i &= \frac{P(X_i = \langle Y_i, c_1 \rangle | \cdot)}{P(X_i = \langle Y_i, c_1 \rangle | \cdot) + P(X_i = \langle Y_i, c_2 \rangle | \cdot)} \\ &= \frac{\lambda P(Y_i | h_1)}{\lambda P(Y_i | h_1) + (1 - \lambda) P(Y_i | h_2)} \\ &= \frac{\lambda h_1^{H_i} (1 - h_1)^{3 - H_i}}{\lambda h_1^{H_i} (1 - h_1)^{3 - H_i} + (1 - \lambda) h_2^{H_i} (1 - h_2)^{3 - H_i}} \end{aligned}$$

$P(Y_i | h_j) = h_j^{H_i} (1 - h_j)^{3 - H_i} \rightarrow$ 当硬币" H "朝上的概率为 p 时, 观察到 Y_i 的概率

$H_i \rightarrow Y_i$ 中" H "朝上的个数

• Maximization Step

$$\begin{aligned} \lambda' &= \frac{\sum_{i=1}^n \tilde{p}_i}{n} \\ h_1' &= \frac{\sum_{i=1}^n \frac{H_i}{3} \tilde{p}_i}{\sum_{i=1}^n \tilde{p}_i} \\ h_2' &= \frac{\sum_{i=1}^n \frac{H_i}{3} (1 - \tilde{p}_i)}{\sum_{i=1}^n (1 - \tilde{p}_i)} \end{aligned}$$





	1	2	3	4	5	6	7	...
	干燥	潮湿	湿透	潮湿	干燥	潮湿	湿透	...
晴	0.80	0.20	0.5	0.05	0.15	0.70	0.10	...
阴	0.10	0.70	0.30	0.05	0.75	0.15	0.05	...
雨	0.10	0.10	0.20	0.90	0.10	0.15	0.85	...

$$\gamma_t(i) = P(q_t = s_i | O, \mu)$$

$$= \sum_{j=1}^N P(q_t = s_i, q_{t+1} = s_j | O, \mu)$$

$$\equiv \sum_{j=1}^N \xi_t(i, j)$$

$$\xi_t(i, j) = P(q_t = s_i, q_{t+1} = s_j | O, \mu)$$


$$= \frac{P(q_t = s_i, q_{t+1} = s_j, O | \mu)}{P(O | \mu)}$$

$$= \frac{\alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)}{P(O | \mu)}$$

$$= \frac{\alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)}{\sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)}$$

$$\alpha_t(i) = P(o_1 o_2 \cdots o_t, q_t = s_i)$$

$$\beta_{t+1}(j) = P(o_{t+2} o_{t+3} \cdots o_T | q_{t+1} = s_j)$$





	1	2	3	4	5	6	7	...
	干燥	潮湿	湿透	潮湿	干燥	潮湿	湿透	...
晴	0.80	0.20	0.5	0.05	0.15	0.70	0.10	...
阴	0.10	0.70	0.30	0.05	0.75	0.15	0.05	...
雨	0.10	0.10	0.20	0.90	0.10	0.15	0.85	...

$$\pi'_i = P(q_1 = s_i \mid O, \mu) = \gamma_1(i)$$

$$a'_{ij} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)}$$

$$b'_j(k) = \frac{\sum_{t=1}^T \gamma_t(j) \times \bar{\alpha}_{o_t, v_k}}{\sum_{t=1}^T \gamma_t(j)}$$



step1 初始化:随机地给参数赋值,使其满足如下约束

$$\sum_{i=1}^N \pi_i = 1$$

$$\sum_{j=1}^N a_{ij} = 1 \quad (1 \leq i \leq N)$$

$$\sum_{k=1}^M b_i(k) = 1 \quad (1 \leq i \leq N)$$

由此得到模型 μ_0 。令 $i = 0$,执行下面的EM估计

step2 EM计算

E-step:由模型 μ_i 计算期望值 $\xi_t(i, j)$ 和 $\gamma_t(i)$

M-step:用*E-step*得到的期望值,重新估计参数 π_i , a_{ij} , $b_i(k)$ 的值,得到模型 μ_{i+1}

step3 循环

令 $i = i + 1$ 。重复执行EM计算,直到 π_i , a_{ij} , $b_i(k)$ 收敛



参数值的初始化

- 重估过程只能保证我们找到一个局部极值。
- 如果我们想要找到全局极值，则要尽量使得HMM在全局极值附近的参数空间开始
 - 粗略估计参数的最佳值（而不是随机设定）
 - 在实践中，好的初始估计对于发射概率是非常重要的
 - 初始概率和转移概率的初始值通常随机估计就够了

本章总结

- 马尔科夫模型
- 隐马尔科夫模型
 - 前向算法
 - 维特比算法
 - BW算法