

自然语言处理

第四章 (I) 常用机器学习模型

目录

Contents

4.1

决策树

4.2

朴素贝叶斯

4.3

支持向量机

4.4

最大熵模型

4.5

Boosting



决策树的**基本思想**：模拟人类进行级联选择或决策的过程，按照属性的某个优先级依次对数据的全部属性进行判别，从而得到输入数据所对应的预测输出。

决策树包含：一个根结点、若干内部结点和叶结点。


其中叶结点表示决策的结果；内部结点表示对样本某一属性判别。

测试序列：从根结点到某一叶子结点的路径。




例如，对于学生的周末安排，需要根据诸如有无作业、有无聚会和天气是否适宜等因素做出安排或决策，左图为一个决策树模型；右图为一个测试序列。（表示某种情况所对应的决策结果）

决策树模型



测试序列





决策树构造的基本思路：

首先根据某种分类规则得到最优的划分特征，计算最优特征子函数，并创建特征的划分节点，按照划分节点将数据集划分为若干部分子数据集；

然后，在子数据集上重复使用判别规则，构建出新的节点，作为树的新分支；

重复递归执行，直到满足递归终止条件。



构造决策树的**关键**：合理选择其内部节点所对应的样本属性，使得节点所对应样本子集中的样本尽可能多地属于同一类别，即具有尽可能高的纯度。

决策树**判别标准**：

第一，如果节点对应数据子集中的样本基本属于同一个类别，则无需对节点的数据子集做进一步划分，否则就要对该节点的数据子集做进一步划分，生成新的判别标准；

第二，如果新判别标准能够基本上把结点上不同类别的数据分离开，使得每个子结点都是类别比较单一的数据，那么该判别标准就是一个好规则，否则需重新选取判别标准。



经验熵：任意给定样本集合 D ，根据熵的本质定义一个量化指标 $H(D)$ 来度量 D 中**样本类型的纯度**。公式为：

$$H(D) = - \sum_{k=1}^n \frac{|C_k|}{|D|} \log_2 \frac{|C_k|}{|D|}$$

n 表示样本标签值的取值状态数；

C_k 表示 D 中所有标注值为 k 的训练样本组成的集合；

$|D|$ 和 $|C_k|$ 分别表示集合 D 和 C_k 的基数

$H(D)$ 值越大，则表明 D 中所包含样本标签取值越杂乱；

$H(D)$ 值越小，则表明 D 中所包含样本标签取值越纯净。



经验条件熵：对于集合 D 上的任意属性 A ，在经验熵 $H(D)$ 的基础上定义一个量化指标 $H(D|A)$ 来度量集合 D 中样本在以属性 A 为标准划分后的纯度。

$H(D|A)$ 的计算公式如下：

$$H(D|A) = \sum_{i=1}^m \frac{|D_i|}{|D|} H(D_i)$$

其中 m 表示属性 A 的取值状态数；

D_i 表示集合 D 在以属性 A 为标准划分后所生成的子集。



信息增益： 在经验熵的基础上进一步计算每个属性作为划分指标后对数据集合经验熵变化的影响。

定义为：

$$G(D, A) = H(D) - H(D|A)$$

若信息增益值越大则表示使用属性A划分后的**样本集合纯度提升越大**，使得决策树模型具有**更强的分类能力**。



下表所示的数据集表示豌豆种子在不同环境下能否发芽情况。豌豆种子自身有形状、大小和种皮颜色等特征，外部影响环境有土壤、水分和日照等特征。试通过下表所示数据集构建决策树并根据最后一行测试数据预测该豌豆能否发芽。

编号	形状	颜色	大小	土壤	水份	日照	发芽
1	圆形	灰色	饱满	酸性	多	12小时以上	否
2	圆形	白色	缢缩	碱性	少	12小时以上	是
3	皱形	白色	饱满	碱性	多	12小时以上	否
4	皱形	灰色	饱满	酸性	多	12小时以下	是
5	圆形	白色	缢缩	碱性	少	12小时以下	是
6	皱形	灰色	缢缩	酸性	少	12小时以上	是
7	圆形	白色	饱满	酸性	少	12小时以下	是
8	皱形	灰色	缢缩	碱性	多	12小时以下	否
9	圆形	灰色	缢缩	碱性	少	12小时以上	否
测试1	圆形	白色	饱满	碱性	多	12小时以下	?



【解】首先计算训练样本数据集的经验熵。

对于训练样本的两个可能取值：能发芽和不能发芽

能发芽占比：5/9

不能发芽占比：4/9

可得，**经验熵**为：

$$H(D) = - \left(\frac{5}{9} \log_2 \frac{5}{9} + \frac{4}{9} \log_2 \frac{4}{9} \right) = 0.99$$



假设以形状作为划分属性，可将集合 D 划分成：

$D(\text{圆形})$ 和 $D(\text{皱形})$

分别计算 $D(\text{圆形})$ 和 $D(\text{皱形})$ 的经验熵：

$$H(D(\text{圆形})) = - \left(\frac{3}{5} \log_2 \frac{3}{5} + \frac{2}{5} \log_2 \frac{2}{5} \right) = 0.97$$

$$H(D(\text{皱形})) = - \left(\frac{2}{4} \log_2 \frac{2}{4} + \frac{2}{4} \log_2 \frac{2}{4} \right) = 1.00$$



由此可得形状属性的信息增益如下：

$$\begin{aligned} G(D, \text{形状}) &= 0.99 - \left(\frac{5}{9} H(D(\text{圆形})) + \frac{4}{9} H(D(\text{皱形})) \right) \\ &= 0.01 \end{aligned}$$

同理可得其他属性的信息增益如下：

$$G(D, \text{颜色}) = 0.09 ; \quad G(D, \text{大小}) = 0.09$$

$$G(D, \text{土壤}) = 0.09 ; \quad G(D, \text{水份}) = 0.23$$

$$G(D, \text{日照}) = 0.09$$



显然，水份属性的信息增益最大，故选择水份作为第一个划分属性，得到图3-10所示的初始决策树

初始决策树






$D(\text{多}) = \{1,3,4,8\}$: 表示水份为多的训练样本集;

$D(\text{少}) = \{2,5,6,7,9\}$: 表示水份为少的训练样本集。

继续对 $D(\text{多})$ 和 $D(\text{少})$ 进行划分, 可得完整决策树。

完整决策树



用所得决策树对测试1样本进行预测?

首先: “水份”为“多”, 故进入左子树;

接着: “日照”在“12小时以下”进入左子;

最后: “大小”为“饱满”。

判断测试1样本**预测结果**: 能够发芽。

目录

Contents

4.1

决策树

4.2

朴素贝叶斯

4.3

支持向量机

4.4

最大熵模型

4.5

Boosting



贝叶斯公式

事件A和B发生的概率: $P(A)$ 和 $P(B)$

B已发生条件下A发生的概率: $P(A|B)$

根据条件概率的定义和性质, 有:

$$P(B|A) = P(B)P(A|B)/P(A)$$



贝叶斯决策

贝叶斯决策：解决的是输出误差或分类错误的问题。

分类任务为： $\mathbf{y} = \{y_1, y_2, \dots, y_n\}$

分类模型： $f(X)$

实际类别为 y_i 的样本 X 被分为 y_j 类的后验概率为：

$$p(f(X) = y_j | X)$$

误判风险： λ_{ij}

混淆矩阵：所有 λ_{ij} 值构成的矩阵，当 $i = j$ 时， $\lambda_{ij} = 0$ ，故混淆矩阵是一个主对角线元素全为0的方阵。



贝叶斯决策

条件期望风险 $R(y_i|X)$:

$$R(y_i|X) = E[\lambda_{ij}] = \sum_{j=1}^n \lambda_{ij} p(f(X) = y_j|X)$$

其中 y_i 表示样本 X 的实际类别； λ_{ij} 表示样本 X 被错误分类的损失函数。

根据贝叶斯公式，可进一步得到：

$$R(y_i|X) = \sum_{j=1}^n \lambda_{ij} \frac{p(f(X) = y_j)p(X|f(X) = y_j)}{p(X)}$$



贝叶斯决策

目标:

$$\arg \min_{y_i} R(y_i|X) = \arg \min_{y_i} \sum_{j=1}^n \lambda_{ij} \frac{p(f(X) = y_j)p(X|f(X) = y_j)}{p(X)}$$

其中 $p(f(X) = y_j)$ 表示模型 $f(X)$ 将样本 X 分类为 y_j 的**先验概率**，通常为训练样本集中类别为 y_j 的样本所占比例， $p(X)$ 为**归一化因子**，对 $f(X)$ 的所有分类类别标记 y_j 均相同。



贝叶斯决策

【例】某种细胞 A 分为正常细胞 w_1 和异常细胞 w_2 。已知先验概率 $P(A \in w_1) = 0.9$ 和 $P(A \in w_2) = 0.1$ ，细胞 A 出现某特征 X 的条件概率为 $P(X|A \in w_1) = 0.2, P(X|A \in w_2) = 0.4$ ，决策损失函数为 $\lambda_{11} = 0, \lambda_{12} = 1, \lambda_{21} = 6, \lambda_{22} = 0$ 。试用贝叶斯决策方法判别细胞 A 出现特征 X 的情况下是否为正常细胞。



贝叶斯决策

【解】 根据贝叶斯公式求出后验概率为：

$$\begin{aligned} P(A \in w_1|X) &= \frac{P(A \in w_1)P(X|A \in w_1)}{P(X)} \\ &= \frac{P(A \in w_1)P(X|A \in w_1)}{\sum_{j=1}^2 P(X|A \in w_j)P(A \in w_j)} = 0.818 \end{aligned}$$

$$\begin{aligned} P(A \in w_2|X) &= \frac{P(A \in w_2)P(X|A \in w_2)}{P(X)} \\ &= \frac{P(A \in w_2)P(X|A \in w_2)}{\sum_{j=1}^2 P(X|A \in w_j)P(A \in w_j)} = 0.182 \end{aligned}$$



贝叶斯决策

依据上述后验概率和决策损失函数 λ_{ij} 可求得将细胞A分类为正常细胞 w_1 和异常细胞 w_2 的**条件期望损失** $R(y_i|X)$ 分别为:

$$R(A \in w_1|X) = \sum_{j=1}^2 \lambda_{1j}P(A \in w_j|X) = \lambda_{12}P(A \in w_2|X) = 0.182$$

$$R(A \in w_2|X) = \sum_{j=1}^2 \lambda_{2j}P(A \in w_j|X) = \lambda_{21}P(A \in w_1|X) = 4.908$$

由于 $R(A = w_1|X) < R(A = w_2|X)$, 故 $A = w_1$ 成立, 即认为A是正常细胞。



贝叶斯分类器

构造贝叶斯分类器步骤：

- 1、计算各种情况下的误判损失值 λ_{ij} ，建立混淆矩阵；
- 2、计算训练样本 X 被分为不同类别的条件风险 $R(y_i|X)$ ；
- 3、最小化每个训练样本条件风险 $R(y_i|X)$ 的方式构建分类模型。



贝叶斯分类器

【例】设有21枚硬币，下表为硬币分类问题训练数据集，其中 X 表示硬币的重量（克）， y 表示硬币的面值（角）。试根据下表中数据构造贝叶斯分类器，并预测一重量为2g硬币的币值。

硬币分类问题训练数据集

编号	1	2	3	4	5	6	7	8	9	10	11
X	2	2	2	2	2	2	2	2	4	4	4
y	1	1	1	1	1	1	1	5	5	5	5
编号	12	13	14	15	16	17	18	19	20	21	
X	4	4	4	4	6	6	6	6	6	6	
y	5	5	1	10	10	10	10	10	10	5	



贝叶斯分类器

【解】首先计算各种情况下的误判损失值 λ_{ij} 并建立混淆矩阵，假设混淆矩阵中元素取值如下表所示。

混淆矩阵取值表

λ_{ij}	1 (角)	5 (角)	10 (角)
1 (角)	0	0.5	0.9
5 (角)	0.2	0	0.6
10 (角)	0.1	0.2	0



贝叶斯分类器

1角硬币共8枚: $p(f(X) = 1) = 8/21$

5角硬币共7枚: $p(f(X) = 5) = 7/21$

10角硬币共6枚: $p(f(X) = 10) = 6/21$

以 $X = 2g$ 为例, 样本特征值的条件概率分别为:

$$p(X = 2|f(X) = 1) = 7/8$$

$$p(X = 2|f(X) = 5) = 1/7$$

$$p(X = 2|f(X) = 10) = 0$$



贝叶斯分类器

由此可得 $y = 1$ 条件风险为:

$$\begin{aligned} R(y = 1|X = 2) &= p(X = 2|y = 1)p(y = 1)\lambda_{11} \\ &+ p(X = 2|y = 5)p(y = 5)\lambda_{12} \\ &+ p(X = 2|y = 10)p(y = 10)\lambda_{13} \end{aligned}$$

同理可得:

$$\begin{aligned} R(y = 5|X = 2) \\ R(y = 10|X = 2) \end{aligned}$$



贝叶斯分类器

由于 $R(y = 1|X = 2)$ 取值最小，故将 $2g$ 硬币判定为1角。
同理可知将 $4g$ 硬币判定为5角及 $6g$ 硬币判定为10角。

由此得到贝叶斯分类器 $f(x)$ 为：

$$f(x) = \begin{cases} 1, & X = 2g \\ 5, & X = 4g \\ 10, & X = 6g \end{cases}$$



朴素贝叶斯分类器

贝叶斯分类器：如果每个训练样本有 n 个属性，每个属性有 m 个取值，则样本空间的规模将达到 m^n 种取值状态。

实际训练样本数通常远小于这个数目，由此，在贝叶斯分类器的基础上构建朴素贝叶斯分类器。

朴素贝叶斯分类器条件独立性假设：认为样本的每个特征之间是相互独立的，不存在依赖关系。



朴素贝叶斯分类器

根据条件独立性假设，可将贝叶斯公式改写为：

$$p(f(X) = y_j | X) = \frac{p(f(X) = y_j) \prod_{k=1}^d p(x_k | f(X) = y_j)}{\prod_{k=1}^d p(x_k)}$$

其中 d 为特征个数， x_i 表示 X 第 i 个属性的取值。

由于其各属性取值概率 $p(x_k)$ 对所有类别均相同，由此可得到朴素贝叶斯分类器的条件风险为：

$$R(y_i | X) = \sum_{j=1}^n \lambda_{ij} p(f(X) = y_j) \prod_{k=1}^d p(x_k | f(X) = y_j)$$



朴素贝叶斯分类器

【例】假设有10个苹果，表3-20为它们的体积、颜色、形状和质量数据，试根据该数据集构造用于判别苹果质量的朴素贝叶斯分类器。

苹果数据集

编号	1	2	3	4	5	6	7	8	9	10
体积	小	大	大	大	大	小	大	小	小	大
颜色	青	红	红	青	青	红	青	红	青	红
形状	非圆	非圆	圆	圆	非圆	圆	非圆	非圆	圆	圆
质量	一般	优质	优质	一般	一般	优质	一般	一般	一般	优质



朴素贝叶斯分类器

【解】首先计算各种情况下的误判损失值 λ_{ij} 并建立混淆矩阵，假设混淆矩阵中各元素的取值为：

$$\lambda_{ij} = \begin{cases} 0, & \text{if } i = j \\ 1, & \text{otherwise} \end{cases}$$

令 $f(X)$ 为所求的朴素贝叶斯分类器；

同时将优质苹果记为1，一般苹果记为0；

根据表可得各类先验概率为：

$$p(f(X) = 1) = 2/5, p(f(X) = 0) = 3/5$$



朴素贝叶斯分类器

同时可得“体积=大”的条件概率为：

$$p(\text{体积} = \text{大} | f(X) = 1) = 3/4, p(\text{体积} = \text{大} | f(X) = 0) = 1/2$$

根据条件风险公式：

$$R(y_i | X) = \sum_{j=1}^n \lambda_{ij} p(f(X) = y_j) \prod_{k=1}^d p(x_k | f(X) = y_j)$$

可得 y 取不同类别值时分错为其它类别的条件风险：

$$R(y = 0 | \text{体积} = \text{大}, \text{颜色} = \text{红}, \text{形状} = \text{圆}) = 0.225$$

$$R(y = 1 | \text{体积} = \text{大}, \text{颜色} = \text{红}, \text{形状} = \text{圆}) = 0.016$$

比较可得：体积大的红色圆形苹果应为优质苹果。



朴素贝叶斯分类器

同理算得其它属性取值状态下最小贝叶斯风险。

综上所述，可构建如下表所示的朴素贝叶斯分类器。

朴素贝叶斯分类器分类结果表

体积	大	大	大	大	小	小	小	小
颜色	红	红	青	青	红	红	青	青
形状	圆	非圆	圆	非圆	圆	非圆	圆	非圆
质量	优质	优质	一般	一般	优质	一般	一般	一般

目录

Contents

4.1

决策树

4.2

朴素贝叶斯

4.3

支持向量机

4.4

最大熵模型

4.5

Boosting



线性可分性


对于分离超平面:

$$\mathbf{w}^T \mathbf{X} + b = 0$$

可以将方点和圆点表示的两类不同数据完全分离在该超平面的两侧, 使其满足:

1、 $\mathbf{w}^T \mathbf{X} + b > 0$ 的所有数据属于一类;

2、 $\mathbf{w}^T \mathbf{X} + b < 0$ 的所有数据属于另一类。



称样本数据集为**线性可分**;


称 $\mathbf{w}^T \mathbf{X} + b = 0$ 为**分离超平面**。



线性可分性

对于一个线性可分性的样本数据集，其分离超平面通常不止一个。

SVM模型：分离超平面使得两类样本数据与该分离超平面形成的间隔均为最大。SVM只输出样本类别而不输出样本属于某一类别的概率。





线性可分性

样本数据集:

$$D = \{(X_1, y_1), (X_2, y_2), \dots, (X_n, y_n)\}$$

其中标签值 y_i 取1或-1，分别代表两个不同类别。

对于超平面: $\mathbf{w}^T \mathbf{X} + b = 0$

样本数据点 $\mathbf{X}$ 到该超平面的距离表示为: $|\mathbf{w}^T \mathbf{X} + b|$

判断 $\mathbf{w}^T \mathbf{X} + b$ 与标记 y 符号是否一致?

若一致，则分类正确；否则，分类错误。

可用 $y(\mathbf{w}^T \mathbf{X} + b)$ 替代 $|\mathbf{w}^T \mathbf{X} + b|$ 表示样本数据点到超平面的距离。



函数间隔

函数间隔: $d_i = y_i(\mathbf{w}^T X_i + b)$

d_i 表示: 样本数据点 X_i 到分离超平面 $\mathbf{w}^T X + b = 0$ 之间的距离。

样本数据集 D 的函数间隔 d 定义为 D 中所有样本数据点到超平面函数间隔的最小值, 即有:

$$d = \min d_i$$

d 作为优化指标构造SVM模型:

$$\max_{\mathbf{w}, b} d; \text{ s. t. } d_i \geq d$$




函数间隔

求得该优化问题的解 w^* 和 b^* ,得到最优分离超平面

$$w^{*T}X + b^* = 0$$

SVM模型:

$$f(X) = \text{sign}(w^{*T}X + b^*)$$





几何间隔

函数间隔的缺点： 若同时同比例缩放其参数向量 w 和偏置量 b ，会改变函数间隔 d_i 的取值。

几何间隔： 解决函数间隔 d_i 取值混乱的问题，对参数向量 w 作归一化后计算得到的函数间隔。



几何间隔

几何间隔:

$\hat{d}_i$ 为函数间隔 d_i 所对应的几何间隔, 则有:

$$\hat{d}_i = \frac{y_i(\mathbf{w}^T X_i + b)}{\|\mathbf{w}\|} = \frac{d_i}{\|\mathbf{w}\|}$$

其中 $\|\mathbf{w}\|$ 为参数向量 $\mathbf{w}$ 的2-范数。

优化问题:

$$\max_{\mathbf{w}, b} \hat{d} = \frac{d}{\|\mathbf{w}\|}; \quad \text{s. t. } \hat{d}_i \geq \hat{d}$$



几何间隔

可在对参数向量 $\mathbf{w}$ 作归一化缩放基础上对其做进一步适当缩放，使得：

$$d = 1$$

最大化 $1/\|\mathbf{w}\|$ 与最小化 $\|\mathbf{w}\|^2$ 等价，故优化问题转化为：

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2; \quad \text{s.t. } y_i(\mathbf{w}^T \mathbf{X}_i + b) - 1 \geq 0$$

求解最优解 $\mathbf{w}^*$ 和 b^* 实现对SVM模型的构造。

用拉格朗日乘数法求解最优解问题。



几何间隔

引入一个拉格朗日因子 a_i ，得到拉格朗日函数：

$$L(\mathbf{w}, b, \mathbf{a}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n a_i [y_i (\mathbf{w}^T \mathbf{X}_i + b) - 1]$$

$\mathbf{a} = (a_1, a_2, \dots, a_n)$ 为拉格朗日因子向量， a_i 的取值非负。

令 $L(\mathbf{w}, b, \mathbf{a})$ 对 $\mathbf{w}$ 和 b 的偏导数分别为 0，则有：

$$\begin{aligned} \frac{\partial L(\mathbf{w}, b, \mathbf{a})}{\partial \mathbf{w}} &= \mathbf{w} - \sum_{i=1}^n a_i y_i \mathbf{X}_i = \mathbf{0} \\ \frac{\partial L(\mathbf{w}, b, \mathbf{a})}{\partial b} &= \sum_{i=1}^n a_i y_i = 0 \end{aligned}$$



几何间隔

得到: $\mathbf{w} = \sum_{i=1}^n a_i y_i \mathbf{X}_i$; $\sum_{i=1}^n a_i y_i = 0$

它们代入 $L(\mathbf{w}, b, \mathbf{a})$ 中消去 $\mathbf{w}$ 和 b , 可得:

$$L(\mathbf{a}) = \sum_{i=1}^n a_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_i a_j y_i y_j \mathbf{X}_i^T \mathbf{X}_j$$

由此可得关于优化问题的对偶问题:

$$\min_{\mathbf{a}} \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_i a_j y_i y_j \mathbf{X}_i^T \mathbf{X}_j - \sum_{i=1}^n a_i ; \quad \text{s.t.} \quad \sum_{i=1}^n a_i y_i = 0$$

可用序列最小化(简称SMO)算法求解上述对偶优化问题。

目录

Contents

4.1

决策树

4.2

朴素贝叶斯

4.3

支持向量机

4.4

最大熵模型

4.5

Boosting



熵的定义

- 定义:

$$H(X) = \sum_{i=1}^k p(x = x_i) \log \frac{1}{p(x = x_i)}$$

- X的具体内容跟信息量无关，我们只关心概率分布，于是 $H(X)$ 可以写成:

$$H(X) = \sum_{x \in X} p(x) \log \frac{1}{p(x)}$$



条件熵

- 有两个变量：x,y。它们不是独立的。已知y，x的不确定度又是多少呢？

$$H(X | Y) = \sum_{(x,y) \in X \times Y} p(x,y) \log \frac{1}{p(x | y)}$$

$$H(X | Y) = H(XY) - H(Y)$$

$$H(X | Y) \leq H(X)$$



最大熵模型

一般形式: $\max_{p \in P} H(Y | X) = \sum_{(x,y)} p(x,y) \log \frac{1}{p(y|x)}$

$P = \{p | p \text{ 是 } X \text{ 上满足条件的概率分布}\}$

What is Constraints?

--模型要与已知知识吻合

What is known?

--训练数据集



特征与样本

特征函数：对于一个特征 (x_0, y_0) ，定义特征函数：

$$f(x, y) = \begin{cases} 1: & \text{如果 } y = y_0 \text{ 而且 } x = x_0 \\ 0: & \text{其他情况} \end{cases}$$

特征函数期望值：

对于一个特征 (x_0, y_0) ，在样本中的期望值是：

$$\overline{p}(f) = \sum_{(x_i, y_i)} \overline{p}(x, y) f(x, y)$$

$\overline{p}(x, y)$ 是 (x, y) 在样本中出现的概率



约束条件

对每一个特征 (x, y) ，模型所建立的条件概率分布要与训练样本表现出来的分布相同。

$$p(f) = \bar{p}(f)$$

假设样本的分布是（已知）： $\bar{p}(x) = x$ 出现的概率

$\bar{p}(x, y) = xy$ 出现的概率 $\bar{p}(f) =$ 特征 f 在样本中的期望值

特征 f 在模型中的期望值：

$$\begin{aligned} p(f) &= \sum_{(x_i, y_i)} p(x_i, y_i) f(x_i, y_i) \\ &= \sum_{(x_i, y_i)} p(y_i | x_i) p(x_i) f(x_i, y_i) \\ &= \sum_{(x_i, y_i)} p(y_i | x_i) \bar{p}(x_i) f(x_i, y_i) \end{aligned}$$



最大熵模型的完整形式

$$p^* = \arg \max_{p \in P} \sum_{(x,y)} p(y|x) \bar{p}(x) \log \frac{1}{p(y|x)}$$

$$P = \left\{ p(y|x) \left| \begin{array}{l} \forall f_i : \sum_{(x,y)} p(y|x) \bar{p}(x) f_i(x,y) \\ \sum_{(x,y)} \bar{p}(x,y) f_i(x,y) \\ \forall x : \sum_y p(y|x) = 1 \end{array} \right. \right\}$$



最大熵模型的解法

- 一般地，对于k个限制条件的Constrained Optimization问题：


$$\max H(p) \quad 1 \leq i \leq k : C_i(p) = b_i$$

- 拉格朗日函数为：

$$L(p, \lambda) = H(p) + \sum_{i=1}^k \lambda_i [C_i(p) - b_i]$$

- 其中引入的拉格朗日算子：

$$\lambda = [\lambda_1, \dots, \lambda_k]^T$$



目录

Contents

4.1

决策树

4.2

朴素贝叶斯

4.3

支持向量机

4.4

最大熵模型

4.5

Boosting



Boosting集成策略

Boosting 集成学习方法，又名提升式集成学习方法。该方法主要通过集成各个弱学习器的成功经验和失败教训实现对模型性的提升。

该方法使用迭代方式完成对各个弱学习器的训练构造，每次迭代对训练样本集的选择都与前面各轮的学习结果有关，使用前面各轮学习结果更新当前各训练样本的权重，对前面被错误预测的赋予较大的权重，实现对当前训练样本集合数据分布的优化。



Boosting集成策略

Boosting 集成学习通常使用两种方式调整训练样本集的数据分布：

- 一是仅调整样本数据的权重，而不改变当前训练样本集合；
- 二是改变当前训练样本集合，将被前面弱学习器错误预测的样本复制到关于当前弱学习器的训练样本集合中重新进行训练。



Boosting集成策略

第一种方式的**基本思想**是**提高**当前训练样本集合中**被错误预测样本的权重**，降低已被正确预测样本的权重，使得后续对弱学习器的训练构造更加重视那些被错误预测的样本。

Boosting 集成学习调整训练样本集的数据分布的第二种方式是**复制**被前面弱学习器**错误预测样本**到样本训练集中重新进行训练。



Adaboost学习算

法

AdaBoost (Adaptive Boosting) 集成学习算法是一种具有自适应性质的Boosting 集成学习算法。该算法的自适应性主要表现在自动提升被错误预测样本的权重，自动减少被正确预测样本的权重，使得弱学习器训练过程能够根据模型预测性能自动进行调整。



Adaboost学习算

现以二分类任务为例介绍该算法的具体过程。对于训练样本集 $D = \{(X_1, y_1), (X_2, y_2), \dots, (X_n, y_n)\}$, 其中 $y_i \in \{-1, +1\}$, 由 AdaBoost 集成学习算法构造集成模型的基本步骤如下:

- (1) 令 $i = 1$ 并设定弱学习器的数目 m 。使用均匀分布初始化训练样本集的权重分布, 令 n 维向量 w^i 表示第 i 次需更新的样本权重, 则有: $w^1 = (w_{i1}, w_{i2}, \dots, w_{in})^T = (\frac{1}{n}, \frac{1}{n}, \dots, \frac{1}{n})^T$
- (2) 使用权重分布为 w^i 的训练样本集 D_i 学习得到第 i 个弱学习器 L_i ;



Adaboost学习算

(3) 计算 L_i 在训练样本集 D_i 上的分类错误率 e_i :

$$e_i = \sum_{k=1}^n w_{ik} I(L_i(X_k) \neq y_k)$$

(4) 确定弱学习器 L_i 的组合权重 a_i 。由于弱学习器 L_i 的权重取值应与其分类性能相关，对于分类错误率 e_i 越小的 L_i ，则其权重 a_i 应该越大，故有：

$$a_i = \frac{1}{2} \ln \frac{1 - e_i}{e_i}$$



Adaboost学习算

(5) 依据弱学习器 L_i 对训练样本集 D_i 的分类错误率 e_i 更新样本权重，更新公式为：

$$w_{i+1,j} = \frac{w_{ij} \exp(-a_i y_k L_i(X_k))}{Z_i}$$

其中：

$$Z_i = \sum_{k=1}^n w_{ij} \exp(-a_i y_k L_i(X_k))$$

为归一化因子，保证更新后权重向量为概率分布；



Adaboost学习算

(6) 若 $i < m$ ，则令 $i = i + 1$ 并返回步骤 (2)，否则执行步骤

(7) 对于 m 个弱分类器 $L_1, L_2, \dots, L_m$ ，分别将每个 L_i 按权重 a_i 进行组合：

$$L = \text{sign}\left(\sum_{i=1}^m a_i L_i(X)\right)$$

得到并输出所求集成模型 L ，算法结束。



Adaboost学习算

AdaBoost 集成学习算法关键要点是如何更新样本权重，即步骤(5) 中的权重更新公式。则可将该公式改写为如下形式：

$$w_{i+1,j} = \begin{cases} \frac{w_{ij}}{Z_i} \exp(-a_i), & L_i(X_k) = y_k \\ \frac{w_{ij}}{Z_i} \exp(a_i), & L_i(X_k) \neq y_k \end{cases}$$

即当某个样本被前一个弱学习器错误预测时，该样本的权重会被放大 $e_i/(1-e_i)$ 倍以便在后续弱学习器构造过程得到应有的重视。